Аналитическая система прогнозирования авиарисков - риск задержки авиарейса.

Дипломный проект по Data Science

- Раздел 1. Введение и актуальность задачи

1.1 Актуальность задачи

Задержки авиарейсов являются одной из ключевых операционных проблем гражданской авиации, оказывая значительное влияние на удовлетворённость пассажиров, логистические процессы авиакомпаний и эффективность работы аэропортов. Существенные задержки рейсов приводят к каскадным эффектам, включая срывы стыковок, перераспределение экипажей, дополнительную нагрузку на наземные службы и финансовые потери.

Современные авиационные системы характеризуются высокой степенью сложности и стохастичности, что затрудняет точное прогнозирование задержек. Тем не менее, наличие исторических данных о рейсах позволяет применять методы машинного обучения для оценки риска задержек на основе закономерностей, выявляемых в данных.

В условиях ограниченности доступной информации до момента вылета рейса особый интерес представляет задача **ранней оценки вероятности значительной задержки**, которая может быть использована в качестве вспомогательного инструмента для принятия управленческих решений.

1.2 Цель и задачи проекта

Целью данного проекта является разработка модели машинного обучения, предназначенной для прогнозирования значительных задержек авиарейсов на основе исторических данных о внутренних авиаперевозках США.

Для достижения поставленной цели в рамках проекта были сформулированы следующие задачи:

- провести анализ реальных данных о рейсах и выявить их основные особенности;

- выполнить очистку и предварительную обработку данных с учётом специфики предметной области;
- разработать набор признаков, отражающих временные, маршрутные и операционные характеристики рейсов;
- обучить и оценить модель машинного обучения для прогнозирования задержек;
- проанализировать ограничения полученной модели и интерпретировать результаты с точки зрения практического применения.

Раздел 2: Процесс добычи и обработки данных

Источник: Датасет авиаперевозок США (2015 год), миллионы записей (Kaggle). Ссылка на датасет вот тут.



Данный датасет был выбран ввиду его ценности – это очень подробный, огромный массив миллионов реальных авиационных рейсов в США, что идеально подходит ТЗ дипломного проекта.

Был взят не весь датасет, но весьма заметная его часть – 2,1 млн строк.

- **Очистка:** Удаление пустых значений в целевой переменной, фильтрация отмененных рейсов.

- **Feature Engineering:**

Помимо использования существующих в датасете признаков (было выбрано 13 из 31, чтобы предотвратить утечку данных), принято решение использовать вытянуть зависимости из данных – создание признаков времени (час, день недели), расчет средних задержек по аэропортам (Target Encoding), расчет расстояний.

Раздел 3: Обоснование выбора модели

- **Выбор:** Градиентный бустинг **CatBoost** (ссылка на GitHub) – «старшая» вариация «Случайного Леса». Модель CatBoost была «обёрнута» в Pipeline.



- **Почему CatBoost:**
  1. Он «из коробки» идеально работает с категориальными признаками (аэропорты, авиалинии, загруженность, типы рейсов).
  2. Устойчив к переобучению.
  3. Позволяет использовать SHAP для интерпретации результатов.

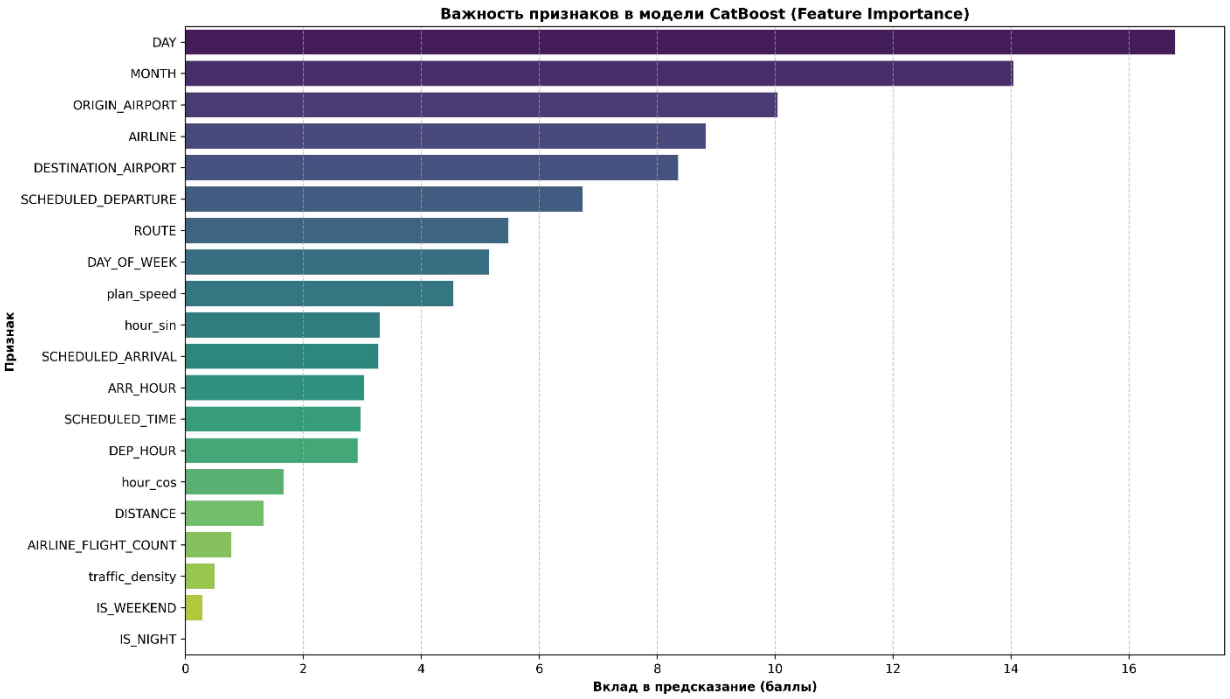
  Категориальный градиентный бустинг CatBoost идеально подходит для подобного рода задач – когда очень много категориальных признаков, помимо основных признаков, представляющие собой числа.

  Его способность напрямую работать с категориальными признаками, а также свойственная для ансамблевых моделей деревьев решений не быть чувствительными к выбросам и масштабам данных, позволяет серьёзно экономить время и вычислительные мощности.

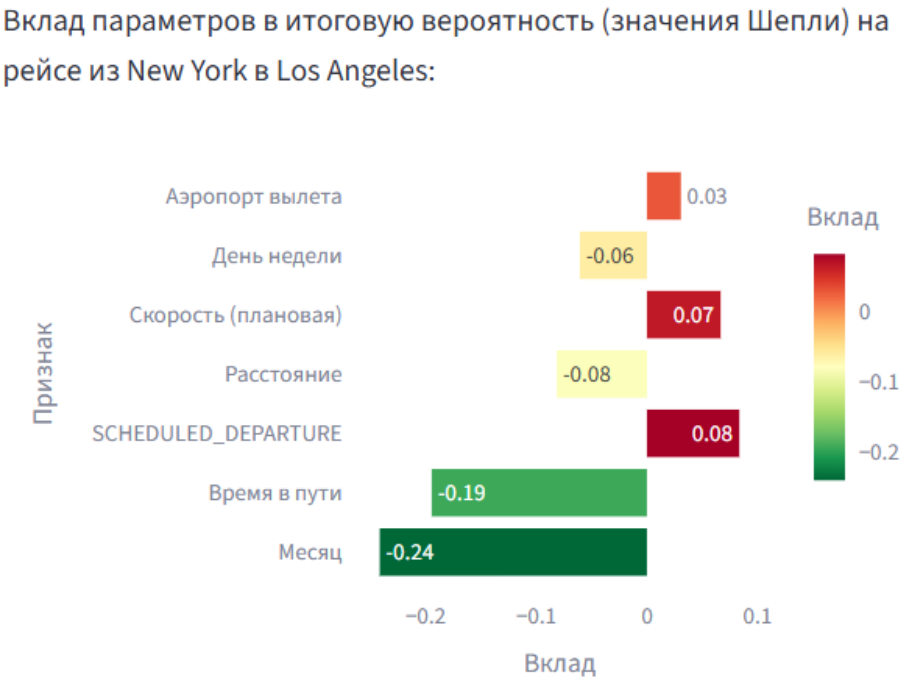
Раздел 4: Технологии и литература

- **Стек:** Python (Pandas, Scikit-learn, CatBoost, Joblib, Pipeline).
- **Интерфейс:** Streamlit (выбран за скорость разработки и удобства визуализации данных) – де-факто стандарт в Data Science для быстрого развёртывания.

- **Интерпретируемость / XAI:** Библиотека SHAP (основана на теории игр Шепли).
- Feature Importance был выбран как основной метод интепретируемости модели CatBoost и просмотра связей, которую она выучила:



Для обеспечения доверия к прогнозу я внедрил модуль XAI (Explainable AI) на базе значений Шепли. Это позволяет не просто выдать прогноз, но и показать, какие именно факторы — например, специфичный маршрут или время вылета — внесли наибольший вклад в итоговую вероятность для конкретно выбранного рейса.



Положительные значения (красный) повышают риск задержки, отрицательные (зеленый) — снижают.

- **Контейнеризация:** Docker (для обеспечения воспроизводимости среды), BAT-файл для запуска в один клик при наличии Python.

Раздел 4: Трудности и решения

- **Трудность:** Огромный объем данных, дисбаланс классов, отсутствие некоторых важных данных в датасете (погода в двух точках маршрута рейса, техническое состояние самолёта, другие признаки вроде забастовок и т.д.).

Была проведена оптимизация данных для экономии памяти и сокращения времени загрузки / обработки данных и обучения модели.

Исследование показало, что при достижении объема в 2 млн+ записей, модель сталкивается с пределом насыщения признакового пространства. Увеличение сложности модели (Lossguide) ведет к переобучению, в то время как консервативные стратегии (SymmetricTree) обеспечивают лучшую обобщающую способность.

Было протестировано множество гиперпараметров модели CatBoost для контроля недообучения/переобучения.

- *Решение:* Оптимизация типов данных (downcast) и использование CatBoost, который эффективно работает с памятью.

- **Трудность:** Дисбаланс классов (задержек меньше, чем вовремя вылетевших рейсов).

В связи с выраженным дисбалансом классов и практической направленностью задачи в качестве основного критерия качества модели рассматривается **Recall** для класса задержанных рейсов.

Такой выбор обусловлен тем, что пропуск задержки в авиации является более критичной ошибкой, чем ложное срабатывание, с точки зрения финансовых расходов. При этом уровень Precision контролируется для обеспечения разумного баланса между полнотой и точностью предсказаний.

Дополнительно для оценки качества модели используется метрика **ROC-AUC**, позволяющая оценить способность модели различать классы независимо от выбранного порога классификации.

- ***Решение**:* Настройка весов классов и подбор гиперпараметров модели и оптимального порога классификации (Threshold) для максимизации Recall.

В ходе исследования была также предпринята попытка внедрения признаков операционной истории (Tail Number, Airport Moving Average – построение скользящих средних по существующим данным). Однако, несмотря на теоретическую обоснованность, это привело к резкому падению ROC-AUC с 0.79 до 0.71. Вероятная причина — высокая дисперсия признаков при большом объеме данных и переобучение модели на специфических идентификаторах бортов – или переобучение модели из-за возможной утечки данных, так как для вычисления скользящих средних использовались те данные из датасета, которые содержали информацию после совершённых рейсов (задержки, отмены, проведённое время руления на ВПП после посадки и т.д.).

В ходе исследования мной была предпринята попытка построения ансамбля (Voting Classifier) на основе CatBoost и LightGBM.

Несмотря на применение техник Target Encoding и оптимизацию типов данных, ансамбль показал результат ниже одиночного классификатора CatBoost: снижение метрики ROC-AUC до 0.7756 по сравнению с 0.7859 у одиночной модели CatBoost. Это объясняется спецификой обработки высококардинальных категориальных признаков (аэропорты, маршруты), в которой алгоритмы CatBoost оказались более эффективными. Усреднение предсказаний с менее точной моделью LightGBM привело к размытию уверенности итогового классификатора.

Формула расчёта издержек (расходов) авиакомпаний при задержках авиарейсов.

$$E(L) = P(delay) \times (C_{direct} \times T_{avg} + C_{pax} \times N_{pax} \times \frac{T_{avg}}{60} + C_{buffer})$$

Где:

- $P(delay)$ — вероятность задержки, предсказанная CatBoost.
- C_{direct} — стоимость минуты задержки для борта (81.18).
- T_{avg} — средняя длительность задержки (52 мин).
- C_{pax} — стоимость часа ожидания пассажира (47).
- N_{pax} — расчетное количество пассажиров на рейсе.

Таким образом, моя модель не просто предсказывает риск задержки. Она позволяет оценить финансовые риски и возможные расходы – что очень важно

для авиационной отрасли и помогает лучше принимать управленческие решения.

Такой комплексный подход превращает классификатор в полноценную систему поддержки принятия решений (DSS).

Методика расчета: FAA Value of Travel Time Savings (VTTS) & Airline Operational Costs.

Источник:

1) Revised Departmental Guidance on Valuation of Travel Time in Economic Analysis (ссылка)

2) FAA - TREATMENT OF TIME (ссылка)